Proteção e Encriptação de Dados de Recursos Humanos

e o seu impacto na análise de clustering

Privacy by Design aplicado a dados de RH — Projeto 2

Segurança e Privacidade de Dados

Dataset: 10.000 registos de colaboradores — RGPD (Regulamento UE 2016/679)

Débora Jesus (

João Coelho (

Índice

1. Introdução 1
1.1. Os três perfis de saída 1
1.2. Questão central 1
2. Descrição dos Dados 1
2.1. Estrutura e tratamento das colunas 1
3. Metodologia 1
3.1. Técnicas de proteção, pseudonimização e codificação aplicadas 1
3.2. Os dois caminhos de clustering 1
3.3. Variáveis, número de grupos e comparação 1
4. Resultados 1
4.1. Escolha do número de grupos 1
4.2. Concordância entre os dois caminhos 1
4.3. Os grupos correspondem aos motivos reais de saída 1
4.4. Perfil dos três grupos 1
4.5. Ficheiros gerados 1
5. Privacidade, Segurança e RGPD 1
5.1. Alinhamento com o RGPD 1
5.2. A peça mais sensível: a tabela de identidade 1
5.3. Limitações 1
6. Conclusão 1
Ferramentas utilizadas 1

1. Introdução

As organizações armazenam diversos dados sobre os seus colaboradores, como idade, datas de entrada e saída, avaliações de desempenho e motivos de saída. Na área de Recursos Humanos, estes dados são úteis para compreender padrões de rotatividade e identificar perfis de saída. Ao mesmo tempo, por serem dados pessoais, exigem cuidados adicionais de proteção e tratamento, em conformidade com o RGPD.

Este projeto parte de uma questão prática: ao proteger os dados antes da análise, a qualidade do clustering é afetada? Para responder a esta questão, comparou-se a análise feita sobre a base original com a análise feita sobre uma versão protegida da mesma base.

Importa ainda uma nota terminológica: embora o título refira «encriptação», as técnicas aplicadas neste projeto são de pseudonimização, generalização e codificação — ou seja, de proteção e anonimização de dados — e não de cifragem reversível no sentido estrito.

1.1. Os três perfis de saída

O objetivo analítico consiste em agrupar os colaboradores que saíram da organização em três perfis, recorrendo a clustering. Como se trata de aprendizagem não supervisionada, o algoritmo forma os grupos com base nas características dos dados, sem utilizar previamente o motivo de saída como variável de treino.

- **C1 — Progressão de carreira:** pessoas mais novas, com boa avaliação, que saíram de forma voluntária.
- **C2 — Saída por underperformance:** baixa avaliação de desempenho e entrevista de saída negativa.
- **C3 — Reforma:** colaboradores mais velhos, com muitos anos de casa.

1.2. Questão central

> **A anonimização dos dados compromete os resultados do clustering?**
>
> Hipótese: os grupos obtidos a partir dos dados protegidos são praticamente os mesmos que os obtidos a partir dos dados originais.
>
> *Métrica: Adjusted Rand Index (ARI). Quanto mais perto de 1,0, mais coincidentes são os dois agrupamentos.*

2. Descrição dos Dados

Foi utilizado um ficheiro CSV com 10.000 registos, dataset_rh_projeto2_original_10000.csv. Cada linha representa um colaborador que saiu da organização. A base contém 10 colunas, respeitando o requisito de 5 a 10 colunas definido para o projeto, e inclui três tipos de informação: identificação pessoal (PII), informação semi-identificadora e variáveis de natureza analítica.

2.1. Estrutura e tratamento das colunas

A tabela seguinte resume as colunas originais, o seu nível de sensibilidade e o tratamento aplicado na versão protegida da base de dados:

Coluna original	Sensibilidade	Versão protegida	Tratamento aplicado
Employee_ID	Alta	Employee_Key	Pseudonimização por hash (SHA-256 com salt)
Age	Média/Alta	Age_Group (+ ordinal)	Generalização em grupos etários (A1–A5)
Gender	Média/Alta	Gender_Code	Codificação categórica (G1…)
Department	Média	Department_Code	Codificação categórica (D1…)
Hire_Date	Média	—	Removida da BD protegida
Exit_Date	Média	—	Removida da BD protegida
Tenure_Years	Média	Tenure_Years	Mantida (necessária à análise)
Performance_Score	Alta	Performance_Score	Mantida (métrica analítica)
Exit_Reason	Alta	Exit_Reason_Code	Codificação categórica (R1…)
Exit_Interview_Score	Alta	Exit_Interview_Score	Mantida (métrica analítica)

As datas de entrada e saída foram removidas da base protegida, uma vez que a variável Tenure_Years já representa a informação temporal necessária para o clustering. No dataset utilizado, a variável Gender inclui três categorias, Department inclui sete departamentos e Exit_Reason inclui os três motivos de saída associados aos perfis C1, C2 e C3.

3. Metodologia

O processo foi desenvolvido num notebook de Python, preparado para execução em Google Colab. A proteção dos dados é aplicada diretamente no notebook: a partir da base original, são geradas a base protegida e as tabelas de mapeamento necessárias para interpretar os resultados. Desta forma, o fluxo completo do projeto fica documentado e reproduzível.

3.1. Técnicas de proteção, pseudonimização e codificação aplicadas

Técnica	Campos	O que faz
Pseudonimização (hash + salt)	Employee_ID	Substitui o identificador por uma chave SHA-256. É unidirecional: da chave não se volta ao ID sem a tabela de identidade.

Técnica	Campos	O que faz
Generalização	Age	A idade exata dá lugar a um grupo etário (26 → A2, 25–34 anos).
Codificação categórica	Gender, Department, Exit_Reason	Os valores passam a códigos sem significado visível (G1, D6, R1).
Remoção	Hire_Date, Exit_Date	As datas completas saem da BD protegida.
Preservação analítica	Tenure_Years, Performance_Score, Exit_Interview_Score	Ficam intactas, por serem necessárias à análise.

Além da base protegida, são geradas duas tabelas de mapeamento: a code_mapping, que permite interpretar os códigos categóricos, e a identity_map, que liga cada Employee_Key ao Employee_ID original. Esta última é a tabela mais sensível do processo e deve ser mantida separada da base usada para análise.

3.2. Os dois caminhos de clustering

Para avaliar o impacto da proteção dos dados, foram comparados dois percursos de análise:

- **Caminho 1:** dados originais → anonimizar → dados protegidos → clustering → desanonimização interpretativa dos resultados.
- **Caminho 2:** dados originais → clustering direto.

Existe uma diferença intencional entre os dois percursos. No Caminho 2 é usada a idade exata, enquanto no Caminho 1 a idade é substituída pelo grupo etário, uma vez que a versão protegida já não contém a idade original. Esta diferença permite medir o impacto real da generalização da idade nos resultados do clustering.

3.3. Variáveis, número de grupos e comparação

O clustering foi realizado com KMeans, utilizando quatro variáveis. No Caminho 2 foram usadas Age, Tenure_Years, Performance_Score e Exit_Interview_Score. No Caminho 1, a variável Age foi substituída pelo grupo etário ordinal, representado por valores de 1 a 5. Antes da aplicação do algoritmo, as variáveis foram normalizadas com StandardScaler.

O número de grupos foi analisado através do método do cotovelo e do coeficiente silhouette, testando valores de k entre 2 e 5. O valor k = 3 apresentou a melhor separação e também corresponde aos três perfis de saída definidos no projeto. Como o KMeans pode atribuir números diferentes a grupos equivalentes, os rótulos dos dois percursos foram alinhados com o algoritmo Húngaro antes da comparação.

4. Resultados

4.1. Escolha do número de grupos

Os resultados do silhouette indicam que k = 3 é a opção mais adequada. Para k = 4 e k = 5 observa-se uma redução da qualidade dos grupos, sugerindo fragmentação desnecessária.

k	Silhouette	Leitura
2	0,37	Grupos pouco definidos
3	0,53	Melhor separação — escolhido
4	0,45	Pior do que k = 3
5	0,32	Fragmentação dos grupos

4.2. Concordância entre os dois caminhos

Os resultados mostram uma elevada concordância entre os dois percursos, mesmo com a substituição da idade exata por grupos etários no Caminho 1:

Métrica	Valor	Leitura
ARI (original vs protegido)	0,9912	Agrupamentos quase idênticos
Registos que mudam de grupo	26 / 10.000	0,26% — efeito da generalização da idade
Silhouette (original)	0,53	Grupos bem separados
Silhouette (protegido)	0,52	Qualidade mantida após proteção

> **ARI = 0,9912 — impacto analítico residual.**
> **A generalização da idade e a remoção das datas completas fizeram com que apenas 26 colaboradores em 10.000 mudassem de grupo. Este resultado indica que a proteção aplicada preservou quase totalmente a estrutura analítica dos dados, sem produzir um valor artificialmente perfeito.**

4.3. Os grupos correspondem aos motivos reais de saída

Foi também comparado cada agrupamento com o motivo de saída real, embora esta variável não tenha sido usada pelo algoritmo no processo de clustering. O ARI obtido foi de 0,95 tanto no clustering original como no clustering protegido, o que indica que os grupos identificados têm uma relação forte com os perfis reais de saída.

4.4. Perfil dos três grupos

A análise dos perfis médios mostra que os três grupos obtidos correspondem aos perfis esperados. Os valores seguintes referem-se ao clustering realizado sobre a base protegida:

Perfil	Registos	Idade média	Antiguidade	Desempenho	Motivo dominante
C1 — Progressão	4.402	31,0	3,2 anos	4,0	Career Progression (99%)
C2 — Underperformance	3.547	39,1	2,6 anos	1,7	Underperformance (97%)
C3 — Reforma	2.051	62,0	24,0 anos	3,6	Retirement (100%)

4.5. Ficheiros gerados

No final do notebook são exportados ficheiros que permitem documentar os resultados e, se necessário, utilizá-los em Power BI:

- **dataset_original_com_clusters.csv** e **dataset_protegido_com_clusters.csv** — as duas bases, já com o cluster e o perfil de cada colaborador.
- **identity_map_restricted.csv** e **code_mapping.csv** — as tabelas de mapeamento (a de identidade é a de acesso restrito).
- **cluster_profile_final.csv**, **comparison_metrics.csv** e um Excel consolidado, **projeto2_resultados_finais.xlsx**.

5. Privacidade, Segurança e RGPD

5.1. Alinhamento com o RGPD

As decisões tomadas no projeto foram alinhadas com princípios relevantes do Regulamento (UE) 2016/679:

- **Minimização dos dados (Art. 5.°, n.° 1, al. c):** o nome, a idade exata e as datas completas não são precisos para o clustering, por isso não entram na base protegida.
- **Limitação da finalidade (Art. 5.°, n.° 1, al. b):** os dados protegidos servem apenas para a análise de RH, sem reidentificação possível sem a chave.
- **Integridade e confidencialidade (Art. 5.°, n.° 1, al. f):** a tabela de identidade fica separada, para que uma fuga da base protegida não exponha as pessoas.
- **Proteção desde a conceção (Art. 25.°):** a privacidade foi pensada à partida, e não acrescentada depois.

5.2. A peça mais sensível: a tabela de identidade

A tabela identity_map estabelece a ligação entre cada Employee_Key e o Employee_ID original. Por esse motivo, é o elemento que torna a pseudonimização reversível. Num contexto real, esta tabela deveria ser armazenada separadamente, encriptada e acessível apenas a utilizadores autorizados. A base protegida, isoladamente, não permite recuperar diretamente a identidade original dos colaboradores.

5.3. Limitações

- A proteção aplicada corresponde sobretudo a pseudonimização, pois existe uma tabela de identidade que permite a reversão controlada. Por isso, não deve ser confundida com anonimização irreversível no sentido mais estrito do RGPD.
- A codificação categórica é reversível quando existe acesso à tabela code_mapping. Técnicas como k-anonimato ou privacidade diferencial poderiam fornecer garantias formais mais fortes, mas não eram necessárias para demonstrar o objetivo principal deste projeto.

- O facto de o ARI não ser exatamente 1,0 mostra que a generalização da idade introduziu um pequeno custo analítico. Neste dataset, o impacto foi residual; no entanto, em bases com mais ruído ou com maior nível de generalização, a perda de detalhe poderia ser superior.

Em contexto de Recursos Humanos, a utilização de variáveis como idade e género deve ser monitorizada para evitar enviesamentos, interpretações discriminatórias ou decisões automatizadas injustas.

6. Conclusão

Os resultados indicam que a proteção dos dados de RH teve um impacto muito reduzido na análise. O clustering sobre os dados protegidos coincidiu com o clustering sobre os dados originais em aproximadamente 99,74% dos colaboradores, com apenas 26 alterações em 10.000 registos (ARI = 0,9912). Além disso, os três grupos obtidos correspondem aos perfis C1, C2 e C3, apresentando uma forte relação com o motivo de saída real, que não foi usado pelo algoritmo.

Assim, conclui-se que foi possível reduzir a exposição de dados pessoais sem comprometer de forma relevante a utilidade analítica da base. A combinação de generalização, codificação, remoção de atributos desnecessários e separação da tabela de identidade permitiu manter a análise de clustering válida, com um custo analítico residual.

Ferramentas utilizadas

Ferramenta	Função
Python 3 / Google Colab	Ambiente de execução do notebook
pandas, numpy	Manipulação e cálculo sobre os dados
scikit-learn	KMeans, StandardScaler, PCA, ARI e Silhouette

Ferramenta	Função
scipy	Alinhamento de rótulos (algoritmo Húngaro)
hashlib (SHA-256)	Pseudonimização do identificador
matplotlib	Visualização dos grupos (incl. projeção PCA 2D)
openpyxl	Exportação do Excel consolidado